


# Modelagem de Baterias

Para uso em BMS

# Abordagem

1. Definir modelo para a bateria
2. Estabelecer quais parâmetros são variáveis, bem como o tempo de variação destes
3. Implementar simulação para estimação dos parâmetros e estados
4. Avaliar imprecisões do modelo e convergência do estimador



# Abordagem


- Há uma grande quantidade de modelos propostos que devem ser analisados por meio de simulações.
- Devido à possibilidade de implementação em sistema embarcado, deve ser observado o *tradeoff* entre precisão e complexidade do modelo
- O aumento da complexidade do modelo e estimador deve ser justificada por divergências em relação a dados experimentais e por erros de estimação.

# Modelos Propostos

# Modelo Simplificado

$$z_{k+1} = z_k - \left( \frac{\eta_i \cdot \Delta t}{c_n} \right) \cdot i_k$$

$$y_k = OCV(z_k) - R \cdot i_k$$



$z_k$  = Estado de Carga, SoC (Estado do modelo)


$y_k$  = Voltagem nos terminais (Saída do Modelo)

# Modelo com Histerese Estática

$$z_{k+1} = z_k - \left( \frac{\eta_i \cdot \Delta t}{c_n} \right) \cdot i_k$$

$$y_k = OCV(z_k) - s_k \cdot M(z_k) - R \cdot i_k$$

$$s_k = \begin{cases} 1, & i_k > \varepsilon \\ -1, & i_k < -\varepsilon \\ s_{k-1}, & |i_k| \leq \varepsilon \end{cases}$$



# Modelo com Histerese dinâmica

- A histerese se torna um estado do modelo, aumentando a complexidade da estimação não só dos parâmetros, como também dos estados

$$\begin{bmatrix} h_{k+1} \\ z_{k+1} \end{bmatrix} = \begin{bmatrix} F(i_k) & 0 \\ 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} h_k \\ z_k \end{bmatrix} + \begin{bmatrix} 0 & 1 - F(i_k) \\ -\left(\frac{\eta_i \cdot \Delta t}{C_n}\right) & 0 \end{bmatrix} \cdot \begin{bmatrix} i_k \\ M(z, \dot{z}) \end{bmatrix}$$

$$y_k = OCV(z_k) - R \cdot i_k + h_k$$

# Filtro de Kalman



# Filtro de Kalman

- Considerando o Sistema: 
$$x_k = Ax_{k-1} + Bu_{k-1} + w_{k-1} \quad (1)$$
$$z_k = Hx_k + v_k \quad (2)$$

- O Filtro de Kalman apresenta as equações de previsão:

$$\hat{x}_k^- = A\hat{x}_{k-1} + Bu_{k-1} \quad (3)$$

$$P_k^- = AP_{k-1}A^T + Q \quad (4)$$

- E de correção:

$$K_k = P_k^- H^T (H P_k^- H^T + R)^{-1} \quad (5)$$

$$\hat{x}_k = \hat{x}_k^- + K_k(z_k - H\hat{x}_k^-) \quad (6)$$

$$P_k = (I - K_k H) P_k^- \quad (7)$$

# Filtro de Kalman Extendido

## (Baseado em Linearização do Sistema)

- Considerando o Sistema: 
$$x_k = f(x_{k-1}, u_{k-1}, w_{k-1}) \quad (1)$$
$$z_k = h(x_k, v_k) \quad (2)$$

- O Filtro de Kalman apresenta as equações de previsão:

$$\hat{x}_k^- = f(\hat{x}_{k-1}, u_{k-1}, 0) \quad (3)$$

$$P_k^- = A_k P_{k-1} A_k^T + W_k Q_{k-1} W_k^T \quad (4)$$

- E de correção:


$$K_k = P_k^- H_k^T (H_k P_k^- H_k^T + V_k R_k V_k^T)^{-1} \quad (5)$$

$$\hat{x}_k = \hat{x}_k^- + K_k (z_k - h(\hat{x}_k^-, 0)) \quad (6)$$

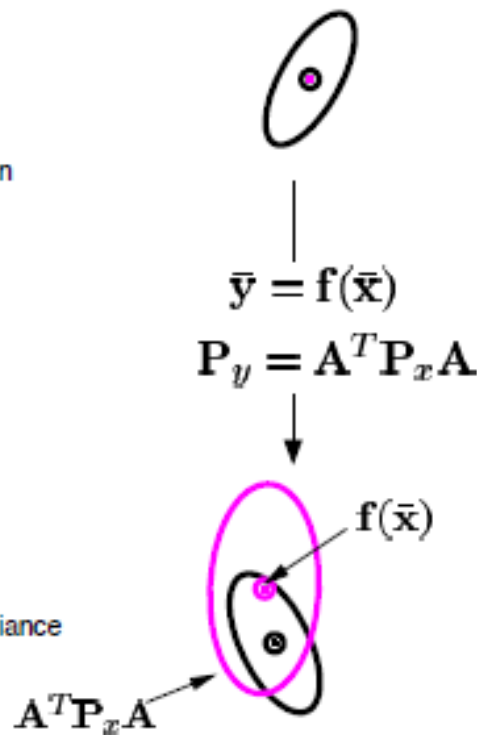
$$P_k = (I - K_k H_k) P_k^- \quad (7)$$

# Filtro de Kalman “Unscented” - Conceito


Actual (sampling)



Linearized (EKF)



UT



# Filtro de Kalman


- O problema é “*dual estimation*”, ou seja, é necessário, a partir de uma medição com ruído, estimar não só os **estados** como também os **parâmetros** do sistema
- A diferença entre estados e parâmetros é a velocidade de variação destes (parâmetros são virtualmente constantes em um curto espaço de tempo)
- Há duas abordagens possíveis para tal problema, utilizar dois filtros de Kalman separadamente (Dual) ou um contendo todos os estados (Joint)

# Simulação


Filtro de Kalman *Unscented*  
Abordagem *com Filtro Duplo*

# Simulação

- Modelo simplificado
- Estimação de parâmetros da curva e dos estados:
  - (1) -  $OCV = (K0 - (K1/(SoC) - K2 * (\log(1 - SoC)))$
  - (2) - Tensão medida =  $OCV - R * i$
  - (3) -  $SoC(k) = SoC(k-1) - C * i$
- Curva de SoC x Tensão (estática):




- Adicionado ruído à medição de tensão



# Simulação

Parâmetros da curva de SoC:



Estados:

